종합설계프로젝트: 중간보고서(요약)

<table>
<tr><td>과 제 명</td><td colspan="5">Openstack 클라우드 환경 내 LLM 워크로드를 위한
GPU 성능 분석: MIG와 PCIe 패스스루를 중심으로</td></tr>
<tr><td>기 간</td><td colspan="5">2026. 03. 02 ~ 2026. 06. 30</td></tr>
<tr><td>팀 명</td><td colspan="5">10조</td></tr>
<tr><td rowspan="4">과
제
참
여
학
생</td><td>학번</td><td>성명</td><td>전화번호</td><td>E-mail</td><td>담당업무</td></tr>
<tr><td></td><td>배지민</td><td></td><td>wlals5853
@knu.ac.kr</td><td>팀장, Openstack 시스템 구축
및 비교 실험 설계, 논문 작성</td></tr>
<tr><td></td><td>김형우</td><td></td><td>7829hw
@gmail.com</td><td>네트워크 설계 및 구축,
GPU 자원 발열 관리,
벤치마크 실행</td></tr>
<tr><td></td><td>배지훈</td><td></td><td>bae031225
@gmail.com</td><td>하드웨어 자원 시각화
인터페이스 구축 및
성능 지표 수집</td></tr>
<tr><td>지금까지
수행내용
(결과)</td><td colspan="5">• Openstack 기반 프라이빗 AI 클라우드 인프라 시스템 아키텍처 설계 및 구축
• KVM/VFIO를 활용한 다중 GPU PCIe Passthrough 할당 환경 구현
• NVIDIA MIG 기술을 적용하여 단일 대용량 GPU의 논리적 자원 분할 적용
• DCGM 및 Prometheus+Grafana 연동을 통한 하드웨어 텔레메트리 실시간 모니터링 구축
• 가상화 오버헤드 검증을 위한 LLaMA 파인튜닝 벤치마크 워크로드 선정 및 세팅</td></tr>
<tr><td>향후
추진할내용
(예상)</td><td colspan="5">• 통제된 VRAM(48GB) 환경에서 4가지 세부 시나리오별 LLaMA 파인튜닝 벤치마크 수행
• MIG 가상 분할 환경과 PCIe 패스스루 물리 환경 간의 연산 성능 비교 분석
• 단일 대용량 GPU(Scale-up)와 다중 분산 GPU(FSDP2) 간의 네트워크 통신 오버헤드 실증 분석
• 수집된 성능/전력/발열 지표를 바탕으로 비용 효율적인 AI 클라우드 인프라 설계 가이드라인 도출 및 논문 작성</td></tr>
</table>

종합설계프로젝트: 중간 보고서

1. 과제내용 및 목표

1.1 목적 및 필요성

- LLM 패러다임 변화에 따른 GPU 자원 수요 폭발: 대규모 언어 모델(LLM)의 파라미터가 기하급수적으로 증가함에 따라, 모델 학습 및 추론에 필요한 VRAM(Video RAM) 용량과 메모리 대역폭이 시스템의 핵심 병목 요인으로 작용함.

- 클라우드 기반 AI 인프라 최적화의 필요성: 연구 기관 및 기업은 제한된 예산 내에서 최적의 AI 환경을 구축해야 함. 고가의 대용량 단일 GPU(Scale-up)와 가성비 중심의 다중 GPU(Scale-out) 구성 중 어떤 방식이 더 효율적인지에 대한 실증적 기준이 부재함.

- 가상화 오버헤드 실증 연구의 부재: 베어메탈(Bare-metal) 환경의 하드웨어 벤치마크는 많으나, 프라이빗 클라우드(OpenStack) 환경에서 필수적인 GPU 가상화 기술(MIG, PCIe Passthrough)이 LLM 연산 효율 및 통신 지연에 미치는 영향을 직접 비교한 연구는 부족함.

- 본 과제는 OpenStack 기반 프라이빗 클라우드를 직접 구축하고, 동일한 VRAM 조건 하에서 MIG 논리 분할과 PCIe 패스스루 물리 할당 방식 간의 LLM 파인튜닝 성능을 실증 비교하여 효율적인 AI 인프라 설계 가이드라인을 제시하고자 함.

1.2 과제의 목표

- OpenStack 기반의 프라이빗 클라우드 인프라(Controller 1대, Compute 2대) 자체 구축

- 이기종(Blackwell/Ada Lovelace) 아키텍처 GPU에 대한 PCIe 패스스루 및 NVIDIA MIG 프로비저닝 환경 구현

- LLaMA 파인튜닝 워크로드 기반의 5가지 GPU 할당 시나리오(Single, MIG, FSDP2) 성능 벤치마크 수행

- 하드웨어 텔레메트리(온도, 전력, PCIe 대역폭, 텐서코어 가동률 등) 수집을 위한 모니터링 파이프라인(Prometheus & Grafana) 구축.

2. 과제 수행 내용

2.1 시스템 분석 및 개념설계

1) H/W 설계

- Control Node (user-Super-Server): OpenStack 제어 및 클러스터 관리 노드.

- Compute Node 1 (Expensive)
  - GPU: NVIDIA RTX PRO 6000 Blackwell (96GB) 1장
  - 단일 대용량 GPU의 성능 검증 및 MIG 기술을 활용한 하드웨어 레벨의 논리적 자원 분할(48GB x 2) 환경 제공

- Compute Node 2 (Cheap)
  - GPU: NVIDIA RTX 6000 Ada Generation (48GB) 4장.
  - 레거시/가성비 다중 GPU 환경 제공 및 FSDP2 기반 분산 학습 환경 테스트베드

2) S/W 설계

- 운영체제 및 하이퍼바이저: Ubuntu 24.04 LTS, KVM(Kernel-based Virtual Machine)

- 클라우드 플랫폼 (OpenStack): Nova(컴퓨팅), Neutron(네트워크), Keystone(인증), Glance(이미지), Placement(자원 스케줄링) 핵심 모듈 구성

- GPU 가상화 드라이버: vfio-pci (물리적 패스스루), NVIDIA vGPU/MIG Manager

- 모니터링 스택:
  - 수집기: NVIDIA DCGM Exporter (GPU 지표), Node Exporter (서버 OS 지표)
  - 저장 및 시각화: Prometheus (시계열 DB), Grafana (대시보드 시각화)

- 벤치마크 워크로드: LLaMA 기반 파인튜닝 (PyTorch FSDP2 활용)

2.2 시스템 설계

그림 1. 본 과제에서 구축한 OpenStack 기반 프라이빗 클라우드 및 GPU 할당 아키텍처. Control Node와 두 개의 Compute Node 간의 역할 분담 및 가상머신(VM) 내부의 컨테이너 환경을 도식화

- Control Node 토폴로지 설계: OpenStack 핵심 서비스(Nova, Placement 등)와 전체 시스템의 상태를 관제하는 모니터링 서비스(Prometheus, Grafana)를 중앙 집중형으로 배치

- Compute Node 1 설계 (MIG 기반 가상화): RTX Pro 6000 Blackwell 96GB를 NVIDIA MIG 기능을 사용하여 다수의 vGPU 인스턴스로 논리적 분할. 그림과 같이 VM-1, VM-2에 각각 분할된 MIG 인스턴스를 패스스루 형태로 매핑하여 자원 격리성 확보

- Compute Node 2 설계 (Passthrough 기반 가상화): 4장의 RTX A6000 Ada를 쪼개지 않고, 각각의 VM에 직접 할당(PCIe Passthrough)하여 통신 오버헤드가 없는 물리적 전용 GPU 환경 구축

제3절 상세설계

1) 벤치마크 실험 시나리오 상세 설계

- LLM 파인튜닝 성능 비교를 위해 총 4가지의 세부 벤치마크 모드를 설계함
- mig48: 96GB GPU를 MIG로 분할한 48GB 인스턴스에서 학습 (가상화 오버헤드 검증)
- single48: 단일 48GB 물리 GPU(A6000 Ada)에서 학습 (통제군)
- single96: 단일 96GB 물리 GPU(PRO 6000) 통째로 학습 (Scale-up 최대 성능)
- fsdp48: 2x 48GB GPU를 Fully Sharded Data Parallel v2 + QLoRA로 학습 (통신 지연 검증)

2) 벤치마크 모델 적용 방법 및 학습 원리

- LLaMA와 같은 수십억 파라미터(Billion-scale) 모델을 48GB VRAM 환경에 적재하기 위해, 사전 학습된 가중치를 4-bit로 양자화(Quantization)하여 메모리 점유율을 극적으로 낮춤.

- 단순 DDP(Distributed Data Parallel) 방식은 각 GPU가 모델의 전체 복제본을 가져야 하므로 메모리 파편화 및 부족 현상이 발생하므로, 이를 회피하고자 FSDP2를 적용하여 모델의 파라미터, 옵티마이저 상태, 그래디언트를 2장의 48GB GPU에 샤딩(Sharding, 조각화)하여 분산 배치함.

- 이를 통해 단일 96GB GPU(single96) 환경과의 총 가용 VRAM 용량을 동일하게 맞추고, 순수 네트워크 통신 오버헤드가 성능에 미치는 영향을 정확히 측정할 수 있는 기반을 마련함.

3) 시스템 모니터링 파이프라인 상세 설계

- 각 VM 내부 Docker 컨테이너에 DCGM Exporter를 배치하여 하이퍼바이저를 거치지 않고 가상머신 내부에서 직접 GPU 원시 지표를 수집하도록 설계함.

- 모델 학습 시 발생하는 PCIe 병목 현상 및 전력 소모량(W)을 실시간으로 분석하여 '비용 대비 성능(Cost-Performance)'을 증명할 정량적 데이터를 확보함.

그림 2. DCGM Exporter와 Prometheus를 연동하여 구축한 Grafana 대시보드. Cheap(Compute 2) 노드와 Expensive(Compute 1) 노드의 GPU 온도, 전력 사용량, PCIe 통신량, 메모리 대역폭 사용률, 텐서코어 가동률을 실시간으로 추적

- Prometheus를 통해 수집하는 주요 DCGM 지표는 다음과 같다.
  - 연산 병목 지표: DCGM_FI_PROF_TENSOR_CORE_ACTIVE (텐서 코어 활성도)

  - 메모리 병목 지표: DCGM_FI_DEV_FB_USED (실시간 VRAM 점유량), DCGM_FI_DEV_MEM_COPY_UTIL (PCIe 메모리 복사 대역폭)

  - 물리적 스로틀링 지표: DCGM_FI_DEV_GPU_TEMP (GPU 코어 온도), DCGM_FI_DEV_POWER_USAGE (실시간 전력 소모량, Watts)

3. 향후 추진할 내용

1) 벤치마크 실험 수행 및 데이터 수집

- 설계된 4가지 시나리오(mig48, single48, single96, fsdp48)에 대한 LLaMA 파인튜닝 실측 테스트 진행.

2) 핵심 지표 추출

- 학습 소요 시간(Training Time), 초당 처리 토큰 수(Tokens/sec), 최대 VRAM 사용량(Peak Memory), 전력 소비량(Power Consumption) 데이터 확보.

3) 실험 결과 교차 분석

- 동일 VRAM(48GB)에서 MIG 가상 분할 vs 물리 단일 GPU 간의 성능 차이 분석.
- 단일 96GB(Scale-up) vs 다중 48GB(Scale-out, FSDP2) 간의 통신 오버헤드 분석.

4) 최종 논문 및 결과 보고서 작성

- 수집된 데이터를 바탕으로 학술 논문 규격에 맞춘 결과 해석 및 가이드라인 도출.

4. 총평

4.1 문제점 또는 난제의 분석 및 해결 내용

1) 물리 GPU의 VFIO-PCI 바인딩 충돌 및 SR-IOV 해제 문제

- 원인: RTX PRO 6000 장치가 부팅 시 하드웨어 레벨에서 SR-IOV(가상 분할 기능)를 활성화하여 다수의 가상 기능(VF)을 생성함. 이로 인해 본체(PF)를 가상머신에 넘겨주기 위한 vfio-pci 드라이버 바인딩 시 Device or resource busy 에러가 발생하며 접근이 차단됨.

- 해결: VM을 생성하기 이전 Bare-metal 환경에서 MIG로 GPU를 분할하지 말고, GPU를 통째로 한 VM에 할당한 후 VM 내에서 MIG를 활용하려 GPU를 논리적으로 분할함.

2) OpenStack Placement 스케줄러의 자원 인식 실패

- 원인: 물리 장치(GPU)가 Compute 노드에 정상적으로 부착되었음에도, Controller 노드에서 VM 생성 시 스케줄러가 대상 호스트를 찾지 못함.

- 해결: Controller의 Placement 자원 장부(Inventory)를 디버깅하여, 인프라에 등록된 GPU의 물리적 리소스 클래스명과 사용자가 요청한 Flavor의 별칭(alias)이 불일치함을 파악함. Flavor의 extra_specs 속성을 실제 장부에 기록된 정확한 식별자로 동기화하여 스케줄링 에러를 해결함.

3) GPU 발열로 인한 성능 저하

- 원인: RTX Pro 6000의 경우, GPU에 냉각을 위한 팬이 존재하지 않아 발열에 취약해 기대 성능의 1/3밖에 내지 못함.

- 해결: 최대한 발열을 상쇄하고자 물리적 서버의 위치를 옮기고, 쿨링 팬을 교체하여 발열 해소 대책을 마련하여 발열로 인한 성능 저하 문제를 해결함.

4.2 최종 작품의 기대효과 및 활용방안

1) 기대효과

- 기존의 하드웨어 벤치마크 논문들과 차별화하여, 'OpenStack 클라우드 가상화 레이어'와 'MIG 분할 기술'이 접목되었을 때 발생하는 복합적인 오버헤드를 LLM 관점에서 분석한 희소성 있는 실증 데이터를 학계에 제공함.

2) 활용 방안

- 제한된 GPU 예산으로 사내 구축형(On-Premise) 프라이빗 AI 클라우드를 도입하려는 기업들에게 최신 고가 장비 1대(Scale-up)와 이전 세대 장비 여러 대(Scale-out) 중 워크로드 특성에 맞는 '가장 비용 효율적인 인프라 투자 가이드라인'을 제시할 수 있음.
- 본 프로젝트를 통해 구축된 'OpenStack 기반 GPU 프로비저닝 및 벤치마크 자동 환경'은 향후 후속 연구나 교내 타 연구실의 AI 서버 인프라 구축 시 즉시 활용 가능한 레퍼런스 아키텍처로 사용될 수 있음.